

Universitat Politècnica de Catalunya

Grau en Intel·ligència Artificial

Processos d'Anàlisi Intel·ligent de Dades

Sistema de suport a la decisió clínica per a la mortalitat per sèpsia a la UCI

Marc Landa, Marina Teruel, Paula Esteve,
Joel Blanco, Pablo Avilés, Veronica Oñate

14 d'abril de 2026



Índex

Abstract	4
1 Introducció	5
1.1 Breu descripció dels objectius per a l'IDSS	5
1.2 A quines decisions es donarà suport?	5
2 Dades usades	5
2.1 Estructura bàsica de les matrius de dades	5
2.2 Explicació de les fonts de dades	6
2.3 Taula de metadata	6
2.4 Idea global sobre els conceptes de coneixement	6
3 Canvas AI	6
4 Definició de l'IDSS	7
5 Descripció dels usuaris	7
6 Arquitectura de l'IDSS	8
7 Disseny del pre-processat de les dades	10
7.1 Esquema del processament	10
7.2 Eines de Programari i Llenguatges de Programació	10
8 Preprocessat de les dades	11
8.1 Anàlisi inicial	11
8.2 Estandardització	15
8.3 Imputació	15
8.4 Outliers	16
8.5 Variables objectiu	17
8.6 Metadata i resultats	17
8.6.1 Taula de metadata de la matriu de treball	17
8.6.2 Taula de metadata de la matriu de treball (definitiva)	18
8.6.3 Resum estadístic de la matriu final	19
9 Models	19
9.1 Data driven	19
9.1.1 Model 1 - Predicció de mortalitat	19
9.1.2 Model 2 - Clustering clínic per al profiling de pacients	22
9.1.3 Profiling dels clústers	23
9.1.4 Model 3 - Explicabilitat i integració amb la capa de coneixement	26
9.2 Knowledge driven	28
9.2.1 Formalisme	28
9.2.2 Estructura principal	28
9.2.3 Font de continguts (experts, literatura, models basats en dades, etc.)	29
9.2.4 Paper en el sistema	29
9.2.5 Forma de l'output, resultats i validació del model	29
9.2.6 Descripció de la integració amb l'arquitectura general	29

13 Conclusions**30**

Abstract

En aquest treball plantegem el disseny d'un *Intelligent Decision Support System* (IDSS) orientat a pacients amb sèpsia ingressats a l'UCI. El nostre objectiu és combinar una capa predictiva de risc de mortalitat, una capa d'explicabilitat i una capa de segmentació clínica mitjançant *clustering*. D'aquesta manera, no només obtenim una probabilitat de risc, sinó també una descripció més rica del perfil del pacient i dels factors que expliquen la predicció del model. En aquesta versió de l'informe desenvolupem especialment la part de *clustering* clínic, perquè és la que ens permet construir fenotips de pacient i donar context a la capa de coneixement del sistema.

1 Introducció

1.1 Breu descripció dels objectius per a l'IDSS

En aquest projecte volem construir un sistema de suport a la decisió clínica per a pacients amb sèpsia a l'UCI. El problema principal que abordem és la predicció de mortalitat hospitalària a partir de variables clíniques, fisiològiques i analítiques disponibles a la base de dades. La nostra idea no és limitar-nos a generar una predicció binària o una probabilitat, sinó construir una solució més completa que integri tres nivells d'informació: el risc estimat pel model, l'explicabilitat d'aquest risc i el fenotip clínic del pacient.

Des del principi hem volgut que l'IDSS tingui una orientació pràctica. Per això hem separat clarament la capa *data-driven*, basada en models i *clustering*, de la capa *knowledge-driven*, que després ha de permetre formular recomanacions o suggeriments d'actuació. Aquesta estructura ens sembla especialment útil perquè permet combinar el que aprèn el model de les dades amb una interpretació més clínica i més propera a l'ús real.

1.2 A quines decisions es donarà suport?

El sistema està pensat per donar suport a decisions de triatge, priorització i monitorització dins el context de l'UCI. En concret, volem ajudar a respondre preguntes com ara: quin és el risc de mortalitat del pacient, si aquest risc requereix una vigilància més estreta, si el pacient encaixa en un fenotip clínic especialment greu i quins factors estan contribuint més a la predicció.

Per tant, l'IDSS no substitueix el criteri clínic, sinó que aporta una capa addicional d'informació estructurada. La nostra intenció és que el sistema serveixi per reforçar decisions com l'activació precoç de protocols, l'augment de la monitorització o la priorització d'un pacient dins el flux assistencial.

2 Dades usades

2.1 Estructura bàsica de les matrius de dades

Hem treballat principalment amb una base de dades de pacients amb sèpsia a l'UCI en format tabular, on cada fila correspon a un episodi clínic i cada columna representa una variable demogràfica, fisiològica, analítica, de severitat o de desenllaç. La matriu principal que hem utilitzat en el projecte és la versió imputada de la base, ja que ens permet treballar amb menys problemes de valors nuls i mantenir una *pipeline* de modelatge més estable.

A nivell conceptual, podem dividir les variables en quatre blocs principals:

- variables demogràfiques i d'ingrés,
- variables de severitat clínica,
- signes vitals i laboratoris,
- variables neurològiques i funcionals.

2.2 Explicació de les fonts de dades

La base de dades que hem utilitzat al llarg del treball és `BaseDatos_imputada_knn.csv`, que correspon a la versió imputada de la cohort de pacients amb sèpsia a l'UCI. Aquesta és la matriu que hem fet servir tant per al *clustering* com per al model supervisat de predicció de mortalitat.

Hem decidit treballar directament amb aquesta versió perquè ja incorpora el tractament dels valors absents i ens permet construir una *pipeline* coherent de modelatge, explicabilitat i segmentació clínica. Per tant, la base imputada és la nostra font de dades operativa i la que sustenta tots els resultats que presentem a l'informe.

2.3 Taula de metadata

A continuació resumim la informació principal de la base de dades sobre la qual hem treballat.

Taula 1: Metadata general de la base de dades

Paràmetre	Detall
Font de dades	Zenodo (<i>Improving sepsis mortality prediction with ML</i> , v2)
Nom del fitxer	<i>Supplementary Table 1. APSIII.csv</i>
Núm. de registres	53.569 episodis clínics
Núm. total de variables	72 variables
Variables numèriques	54 (signes vitals, analítiques i <i>scores</i>)
Variables binàries	3 (<i>gender</i> , <i>hospital_expire_flag</i> , <i>sepsis3</i>)
Variables qualitatives	8 (<i>ethnicity</i> , <i>admission_type</i> , <i>marital_status</i> , etc.)
% de valors absents	Aproximadament un 15–20% global (amb variables >50%)

2.4 Idea global sobre els conceptes de coneixement

A nivell de coneixement clínic, la base es pot entendre com una combinació de severitat global, estat hemodinàmic, alteració metabòlica, estat neurològic i resposta inflamatòria. Aquesta idea ens ha ajudat tant a seleccionar variables per als models com a interpretar posteriorment els clústers. En lloc de tractar cada variable de manera aïllada, hem intentat veure quins eixos clínics apareixen de manera recurrent en els resultats.

3 Canvas AI

A continuació incloem el Canvas que vam desenvolupar al començament del projecte per tal de definir els elements principals que conformen el projecte. Aquesta eina ens ha permès estructurar la base de la proposta, des de la definició de la tasca clínica i la proposta de valor, centrada en la detecció precoç de la mortalitat per sèpsia, fins a la identificació dels riscos, les barreres tecnològiques i els criteris de decisió. Aquest esquema serveix com a full de ruta per al desenvolupament de l'IDSS, assegurant que la solució

tecnològica estigui alineada amb les necessitats del context i l'objectiu final de reduir la mortalitat.

Projecte: Sepsis IDSS			
La tasca i la decisió	Proposta de Valor	Judici (criteri de decisió)	Desplegament
Quina tasca vols automatitzar? El monitoratge clínic i pronòstic de pacients crítics ingressats amb diagnòstic de sepsis a la Unitat de Cures Intensives (UCI).	Quin valor proporciona una solució basada en IA? Proporciona una "alerta" primerenca automatitzada que detecta patrons subtils en les constants vitals i analítiques que precedeixen una fallada multiorgànica.	Quin preu estic disposat a pagar pels errors del sistema? S'ha de prioritzar la sensibilitat (evitar falsos negatius), ja que no detectar un pacient crític té un cost vital alt. Un fals positiu implica una revisió mèdica addicional (cost operatiu).	Què em falta per posar en marxa aquest projecte? - Inserció: Connexió del sistema als sensors de l'UCI per rebre dades en temps real. - Infraestructura: Configuració del servidor per executar el model i la interfície als ordinadors de la UCI.
Quina decisió es pot millorar amb IA? La identificació de pacients amb alt risc de mortalitat per a la prioritització d'intervencions mèdiques agressives o reajustament de tractaments.	Dades	Resultat	Què em falta per posar en marxa aquest projecte? - Validació: Fase de prova per validar alertes contra el mètode APSIII actual. - Formació: Capacitació del personal sobre la interpretació d'alertes i protocols d'actuació.
Quin aspecte vols millorar? La capacitat de predicció de la supervivència (hospital, sobre, flag) mitjançant els scores estàndard com l'APACHE II, per reduir el temps de reacció.	Tenim accés a les dades necessàries? Sí. Disposem de 53.556 registres amb 72 variables que inclouen: demografia, tipus d'admissió, constants vitals (HR, MAP, Temp, Resp) i analítiques (Creatinina, BUN, Sodí, Glucosa, VSG).	Com podem mesurar l'èxit del projecte? Millora de l'AUC-ROC en comparació amb el model APS III actual i, a llarg termini, una reducció de la taxa de mortalitat hospitalària en pacients amb sepsis.	
Riscos	Barres		
Quins són els principals riscos? Baix en les dades (per exemple, per ètnia o edat), dependència excessiva de l'etiqueta ("clinical inertia") i possibles errors en la recollida automatitzada de les constants vitals.	Quins aspectes poden posar en perill el projecte? Resistència al canvi del personal sanitari, problemes d'interpretabilitat entre els sensors mèdics i el programari d'IA, i regulacions de protecció de dades (GDPR).		

Figura 1: Canvas AI del projecte

4 Definició de l'IDSS

L'*Intelligent Decision Support System* (IDSS) presentat en aquest projecte es defineix com una eina dissenyada específicament per assistir el personal sanitari en la gestió de pacients amb sèpsia ingressats a la Unitat de Cures Intensives (UCI). A diferència dels *scores* estàndard de severitat, aquest sistema no es limita a oferir un valor numèric aïllat, sinó que integra múltiples dimensions d'anàlisi per oferir una visió molt més àmplia sobre el pacient concret.

L'arquitectura del sistema es basa en la combinació de tres nivells d'informació estructurada:

- **Estimació de risc quantitatiu:** una capa *data-driven* que, mitjançant el model supervisat XGBoost, calcula la probabilitat individual de mortalitat hospitalària basada en variables fisiològiques, analítiques i demogràfiques.
- **Contextualització per fenotips:** una capa de segmentació clínica basada en *clustering* que assigna cada pacient a un perfil o fenotip específic (com el renal-metabòlic o el neurològic-inflamatori). Això permet entendre que dos pacients amb el mateix risc poden requerir enfocaments diferents segons la seva naturalesa clínica.
- **Explicabilitat i coneixement:** una capa que interpreta les prediccions del model i les connecta amb una base de coneixement (*knowledge-driven*) per generar recomanacions o alertes d'actuació.

Aquest IDSS està pensat com un sistema d'alerta primerenca, essent la seva funció principal detectar patrons subtils en les constants vitals i dades de laboratori que predeixen una fallada multiorgànica, permetent la prioritització d'intervencions i l'activació de protocols de monitorització.

És important subratllar que aquest sistema s'ha dissenyat per ser una eina complementària que no substitueix el criteri clínic, sinó que el reforça aportant informació estructurada i objectiva que pot ser vital en entorns d'alta pressió assistencial com l'UCI.

5 Descripció dels usuaris

L'IDSS proposat en aquest treball està orientat principalment a professionals de l'àmbit clínic que intervenen en la gestió de pacients amb sèpsia ingressats a la UCI. Com que

el sistema s'ha concebut com una eina de suport a la decisió i no com un mecanisme de substitució del criteri mèdic, els seus usuaris són aquells perfils que necessiten interpretar informació clínica complexa i prendre decisions en un entorn assistencial d'alta pressió. En aquest sentit, el sistema no decideix de manera autònoma, sinó que aporta una capa addicional d'informació estructurada que ajuda a valorar millor la situació del pacient. Aquesta visió és coherent amb la lògica general dels IDSS, on l'usuari final continua sent responsable d'acceptar, refinar o rebutjar les solucions proposades pel sistema.

El primer i més important perfil d'usuari és el personal mèdic de la UCI, especialment metges i metgesses intensivistes. Aquest és l'usuari principal del sistema, ja que és qui ha d'interpretar el risc estimat de mortalitat, el fenotip clínic assignat i els factors que expliquen la predicció. Per a aquest perfil, l>IDSS serveix com a suport en decisions de triatge, priorització de casos, intensificació de la vigilància i possible activació precoç de protocols d'actuació. L'objectiu no és substituir la valoració clínica, sinó reforçar-la amb una estimació quantitativa i una contextualització més completa del perfil del pacient.

Un segon perfil rellevant és el personal d'infermeria de la UCI. Tot i que no assumeix habitualment la decisió diagnòstica o terapèutica final, sí que participa de manera molt directa en el seguiment continu del pacient i en la detecció precoç de canvis clínics. En aquest context, el sistema pot ser útil per identificar pacients que requereixen una monitorització més estreta o una revisió clínica ràpida, especialment quan el risc predit és elevat o quan el perfil clínic del pacient encaixa amb fenotips més greus.

Finalment, també es pot considerar com a usuari el personal responsable de coordinació clínica o supervisió de la unitat. Aquest perfil no necessàriament utilitza el sistema per analitzar cada pacient en profunditat, sinó per tenir una visió de suport en la priorització assistencial i en l'organització de recursos dins la UCI. En situacions amb diversos pacients crítics simultanis, una eina d'aquest tipus pot ajudar a identificar quins casos requereixen una atenció més immediata o una vigilància reforçada.

En conjunt, els usuaris del nostre IDSS són, sobretot, professionals sanitaris vinculats a la presa de decisions i al seguiment de pacients amb sèpsia a l'UCI. Per tant, el sistema s'ha concebut com una eina d'ajuda a la interpretació clínica i a la priorització assistencial, sempre subordinada al coneixement expert i al criteri del personal mèdic.

6 Arquitectura de l>IDSS

La nostra arquitectura d>IDSS s'ha dissenyat com un flux integrat que transforma dades clíniques brutes en informació estructurada que serveixi com a ajuda a la presa de decisions mèdiques. Tot això segueix el nostre objectiu principal del projecte, que no és només estimar la mortalitat hospitalària en pacients amb sèpsia, sinó oferir una sortida interpretable i clínicament útil per al personal sanitari, mantenint sempre present la supervisió d'un professional.

El punt d'entrada de l'arquitectura és la base de dades clínica, que recull la informació demogràfica, fisiològica i analítica dels pacients amb sèpsia ingressats a la UCI. Abans de qualsevol modelatge, aquestes dades passen per una etapa de preprocessament on es duen a terme la codificació de variables categòriques, la detecció i tractament de valors

absents mitjançant imputació KNN, la revisió de valors inconsistents i l'anàlisi d'*outliers*, així com la selecció de variables. El resultat d'aquesta etapa és una base preprocessada que s'utilitzarà a tots els components posteriors del sistema.

A partir d'aquesta matriu preprocessada, l'arquitectura es divideix en dues capes *data-driven* complementàries. La primera és el model supervisat de predicció de mortalitat, implementat amb XGBoost, que calcula per a cada pacient una probabilitat individual de mort hospitalària. Aquesta probabilitat es transforma en una discretització en risc baix, mitjà o alt, de manera que la sortida sigui més interpretable i més fàcil d'utilitzar en un entorn clínic. La segona és la capa de *clustering* clínic, que assigna cada pacient a un fenotip clínic a partir de les seves característiques fisiològiques i analítiques. Això permet contextualitzar millor el risc, ja que dos pacients amb una probabilitat de mortalitat similar poden pertànyer a fenotips clínics diferents i, per tant, requerir una assistència sanitària també diferent. En el nostre cas, aquesta segmentació es reforça amb un *profiling* tipus aTLP, que ajuda a descriure de manera més clara els trets dominants de cada clúster.

Sobre aquestes dues sortides s'afegeix una capa d'explicabilitat i coneixement. D'una banda, el sistema identifica quines variables han influït més en el risc predit de mortalitat. De l'altra, la informació generada pels models es combina amb una base de coneixement experta, que incorpora criteris clínics i permet donar més sentit a la interpretació del cas. Per facilitar aquesta integració, es construeix un context clínic estructurat del pacient en format JSON, on s'agrupen la probabilitat predita, el nivell de risc, el fenotip clínic assignat i els principals factors explicatius. Aquest context estructurat serveix de pont entre la part analítica i la part interpretativa del sistema.

La sortida final de l'IDSS es genera en llenguatge natural i està pensada perquè el personal mèdic pugui entendre ràpidament la situació del pacient sense haver d'interpretar únicament valors aïllats o resultats tècnics. D'aquesta manera, el sistema no només informa del risc, sinó que resumeix el perfil clínic i destaca els elements que justifiquen la seva estimació. Aquesta informació dona suport a la decisió mèdica, especialment en tasques de triatge, priorització i monitorització dins la UCI. Tot i això, l'arquitectura manté explícitament una lògica *human-in-the-loop*, ja que la decisió final continua depenent del personal sanitari i el sistema actua únicament com una eina complementària de suport. Aquesta visió és coherent amb la definició general del projecte i amb el perfil d'usuaris identificat, principalment metges i metgesses intensivistes, personal d'infermeria i responsables de coordinació clínica.

Finalment, l'arquitectura incorpora un mecanisme de retroalimentació que connecta la decisió mèdica amb el registre de decisions i resultats obtinguts. Aquesta informació no només permet fer un seguiment de l'ús real del sistema, sinó que també obre la porta a un reentrenament periòdic dels models amb noves dades, fent possible una actualització progressiva de l'IDSS a mesura que s'amplia l'experiència clínica acumulada. Així, la nostra arquitectura no s'entén com una estructura tancada, sinó com un sistema evolutiu que combina dades, models i coneixement expert per oferir una ajuda cada vegada més robusta, contextualitzada i útil per a la pràctica clínica.




Figura 2: Arquitectura general de l'IDSS

7 Disseny del pre-processat de les dades

7.1 Esquema del processament

Per tal de garantir la reproductibilitat i l'ordre lògic en la preparació de les dades, s'ha dissenyat un flux de treball seqüencial. La figura següent mostra el diagrama de flux global del preprocessament, que parteix de la matriu crua i aplica, pas a pas, les tècniques de neteja, estandardització i imputació fins a obtenir la base de dades consolidada que alimentarà els models predictius. L'explicació detallada de cadascun d'aquests blocs es desenvolupa a l'apartat següent.



Figura 3: Esquema global del processament de dades

7.2 Eines de Programari i Llenguatges de Programació

Per al desenvolupament d'aquest *Intelligent Decision Support System* (IDSS), s'ha establert com a base tecnològica el llenguatge de programació Python. L'elecció d'aquest llenguatge es fonamenta en la seva robustesa, la seva àmplia adopció en el camp de la Intel·ligència Artificial i la seva capacitat per unificar tot el flux de treball, des de la neteja de dades fins a la implementació de models d'explicabilitat, a més de ser l'eina que hem fet servir més durant la carrera i amb la qual estem més familiaritzats.

Pel que fa a les eines de programari i llibreries específiques, el projecte s'ha recolzat en el següent ecosistema tècnic:

- **Manipulació i anàlisi de dades:** s'han utilitzat *pandas* i *numpy* com a estructures centrals per a la càrrega, recodificació, filtratge estadístic i operacions vectorials sobre la matriu clínica.

- **Preprocessament i clustering:** s'ha emprat `scikit-learn` per dissenyar la *pipeline* de dades. Aquesta eina ha estat fonamental per a la imputació espacial (`KNNImputer`), l'estandardització de les distribucions i l'execució dels diversos algorismes de segmentació no supervisada (com `KMeans` o `Birch`).
- **Modelatge predictiu:** el nucli predictiu d'avaluació de risc s'ha construït amb la llibreria `xgboost`, escollida per la seva alta eficiència computacional i el seu rendiment òptim sobre dades tabulars heterogènies.
- **Visualització:** per a l'anàlisi exploratòria de dades (EDA) inicial, la generació dels mapes de calor de correlació i la inspecció visual d'*outliers*, s'han utilitzat les llibreries gràfiques `matplotlib` i `seaborn`.

A nivell d'entorn de treball, el desenvolupament s'ha organitzat combinant *Jupyter Notebooks* (per a l'exploració interactiva durant la fase d'EDA) i *scripts* modulars de Python (`.py`) per automatitzar de manera seqüencial les tasques de neteja, entrenament i generació de resultats.

8 Preprocessat de les dades

8.1 Anàlisi inicial

L'anàlisi exploratòria de dades ha estat el pas fonamental per entendre el perfil clínic dels pacients i diagnosticar l'estat de la base de dades abans de qualsevol intervenció. L'objectiu no ha estat corregir la dada, sinó observar la seva naturalesa i justificar les accions de preprocessat posteriors.

S'ha treballat amb una cohort inicial de 53.569 episodis de sèpsia a l'UCI. L'anàlisi de la variable objectiu, `hospital_expire_flag`, revela una taxa de mortalitat del 10,1%, cosa que indica un desequilibri de classes important que caldrà tenir en compte en l'entrenament dels models predictius. Les distribucions demogràfiques mostren una població d'edat avançada amb una alta comorbiditat, reflectida en *scores* de severitat inicials elevats.

Mapa de missings i qualitat de la dada. L'anàlisi univariant ha permès identificar una presència de valors absents molt heterogènia. S'ha detectat que determinades variables crítiques, com l'escala de Glasgow (`gcs_score`), la temperatura o la diüresi, presentaven nivells de *missing* inferiors al 10%, fet que les fa molt fiables per al modelatge. En canvi, variables com `sepsis3` o paràmetres analítics específics mostraven buits superiors al 50%, la qual cosa ha estat el motiu principal per plantejar una estratègia d'eliminació selectiva i imputació avançada en les etapes següents.

Variabilitat clínica i extrems. Mitjançant l'ús de *boxplots* i *histograms*, s'ha explorat la variabilitat dels signes vitals i analítics. S'ha observat una presència significativa de valors extrems (*outliers*) en variables com la pressió arterial, la freqüència cardíaca o els nivells de creatinina. L'anàlisi estadística mitjançant el rang interquartílic (IQR) i el *Z-score* ha confirmat que aquests valors, tot i ser estadísticament anòmals, tenen coherència amb la gravetat de pacients crítics amb fracàs multiorgànic.

Relacions bivariants i correlacions. Finalment, s'ha analitzat com interaccionen les variables entre si i amb la mortalitat. S'ha identificat una correlació positiva clara entre l'*score* de gravetat `apsiii` i el desenllaç final, així com relacions lògiques entre la disfunció




Figura 5: APSII

renal (*creatinina*, *BUN*) i l'augment del risc predit. Aquesta inspecció inicial ha permès seleccionar els eixos clínics que realment aporten informació discriminativa per al sistema de suport a la decisió.

Resultats visuals: Anàlisi univariant.

L'edat d'ingrés mostra una distribució concentrada principalment entre els 60 i els 80 anys. Aquest patró és altament coherent amb l'epidemiologia típica de la sèpsia a les Unitats de Cures Intensives, on la incidència i vulnerabilitat augmenten significativament en edats avançades.




Figura 4: Admission Age

L'espectre de gravetat (*apsiii*) presenta una distribució gairebé contínua amb un lleuger biaix cap a la dreta. Això reflecteix la gran heterogeneïtat clínica de la cohort, que inclou des de pacients estables fins a casos amb un compromís fisiològic extrem ja en el moment de l'ingrés.

La identificació visual de valors extrems (*creatinine_max*) revela una forta asimetria positiva amb una gran concentració en valors baixos i una cua dreta molt allargada. Aquesta forma evidencia la presència de valors que són estadísticament atípics (*outliers*), però que clínicament representen la disfunció renal greu en un subgrup de pacients. Aquest




Figura 6: creatine max





Figura 7: apsiiii vs hospitalexpireflag

comportament és precisament el que ha fet necessari l'estudi específic de valors extrems desenvolupat a l'apartat 10.4.


Resultats visuals: Anàlisi bivariant.

Dins l'estudi vam observar que el diagrama de caixa revela una diferència estadística molt significativa en els nivells de l'*score* *apsiii* entre els pacients supervivents i els que acaben morint. La mediana del grup de mortalitat (valor 1) se situa clarament per sobre del tercer quartil del grup de supervivència (valor 0), confirmant que la gravetat acumulada mesurada en les primeres 24 hores és el predictor més potent del desenllaç final.

També hem pogut observar que, en creuar les variables analítiques amb la mortalitat, els pacients amb èxits presenten rangs de creatinina significativament més elevats i valors en l'escala de Glasgow (*gcs_score*) més baixos. Aquesta relació bivariant és especialment visible en la presència d'*outliers* extremadament alts en creatinina per al grup de risc, fet que reforça la necessitat de mantenir aquests valors atípics per capturar la realitat del fracàs renal agut.



(a) gcs score vs hospitalexpireflag



(b) creatinie max cs hospitalexpireflag

Correlació.

S'observa una correlació positiva rellevant entre la mortalitat i l'índex de gravetat global `apsiii`, així com amb els marcadors de fracàs renal (com `bun_max` o `creatinine_max`). De manera inversa, paràmetres com la producció d'orina (`urineoutput`) o l'escala de Glasgow (`gcs_score`) mostren correlacions negatives, confirmant clínicament que valors baixos en aquestes mètriques s'associen a un pitjor pronòstic.




Figura 9: Correlació

El mapa de calor revela blocs d'alta colinealitat esperats entre variables fisiològicament lligades (per exemple, entre els diferents indicadors renals o hemodinàmics). Tot i que l'algorisme XGBoost que s'implementarà a la capa predictiva és robust davant d'aquestes redundàncies, tenir-les cartografiades resulta fonamental per garantir una correcta interpretació a la capa d'explicabilitat (XAI) i per entendre el pes de les variables en la construcció dels fenotips durant el *clustering*.

Finalment, pel que fa a les variables categòriques (com ara dades demogràfiques o detalls administratius de l'ingrés), el seu estudi visual s'ha omès d'aquest apartat en favor de la seva recodificació directa per al modelatge (vegeu l'apartat 10.2). Aquesta decisió respon a un criteri clínic i predictiu: tot i que aquestes variables aporten context, l'anàlisi

exploratorià inicial ha demostrat que la variància explicativa de la mortalitat per sèpsia recau fonamentalment en les alteracions fisiològiques contínues (com el deteriorament neurològic o el fracàs renal). Per tant, s'ha prioritzat la representació visual d'aquests marcadors crítics.

8.2 Estandardització

En aquesta fase es va dur a terme l'estandardització del conjunt de dades amb l'objectiu d'homogeneïtzar formats, categories i valors abans d'aplicar tècniques d'imputació i modelització. En primer lloc, es va transformar el fitxer original perquè totes les variables numèriques utilitzessin la coma com a separador decimal i el punt i coma com a delimitador de camps. Aquesta transformació va permetre treballar posteriorment amb un format coherent en tots els fitxers generats durant el preprocessament.

Tot seguit, es va revisar la variable `ethnicity`, ja que presentava un nombre elevat de categories amb una granularitat excessiva per a l'anàlisi posterior. Per aquest motiu, es van agrupar les categories originals en sis grups més generals: *White*, *Black*, *Asian*, *Hispanic/Latino*, *Multiple/Other* i *Unknown*. Aquesta recodificació va permetre reduir la dispersió de valors i facilitar la interpretació dels resultats.

Posteriorment, es van identificar les variables categòriques del conjunt de dades i es van codificar numèricament per poder-les incorporar als procediments d'anàlisi i imputació. Les variables codificades van ser `gender`, `ethnicity`, `admission_location`, `admission_type`, `marital_status` i `sepsis3`. La codificació es va fer assignant un codi enter a cada categoria segons la seva freqüència, i es va generar addicionalment un diccionari de correspondències entre categoria, codi i freqüència per garantir la traçabilitat del procés.

Dins d'aquesta etapa d'estandardització també es van revisar valors inconsistents. En concret, es van detectar valors negatius a `hospitaldischargeoffset`, `los_hospital`, `deathoffset` i `urineoutput`. En els tres primers casos, els registres afectats es van eliminar perquè el signe negatiu no era compatible amb el significat de la variable. En el cas de `urineoutput`, els valors negatius es van recodificar com a absents. Aquest procés va comportar l'eliminació de 76 observacions.

Finalment, es van eliminar les variables de tipus data i data-hora, concretament `admittime`, `disctime`, `icu_intime`, `icu_outtime` i `dod`, ja que no s'havien de fer servir directament en la modelització i podien introduir complexitat addicional si es mantenien en el seu format original.

8.3 Imputació

Una vegada estandarditzat el conjunt de dades, es va analitzar la presència de valors absents per determinar quines variables requerien un tractament específic. En primer lloc, es van identificar aquelles variables amb més del 50% de valors perduts, ja que una proporció tan elevada d'absència feia poc recomanable la seva conservació. Seguint aquest criteri, es van eliminar les variables `aado2`, `pao2`, `pao2_aado2_score`, `albumin_max`, `albumin_min`, `albumin_score`, `acidbase_score`, `paco2`, `ph`, `bilirubin_max`, `bilirubin_min`, `bilirubin_score` i `deathoffset`.

Tot i que els *missings* a `deathoffset` pertanyien a gent que no havia mort a l'hospital (i, per tant, no constava el temps transcorregut fins a la mort), es va decidir eliminar-la ja que ja comptàvem amb la variable `hospital_expire_flag`, que indica si ha mort o no

durant l'estància a l'hospital.

Després d'aquesta selecció inicial, es va aplicar una imputació mitjançant l'algorisme *K-Nearest Neighbors* (KNN), utilitzant un model `KNNImputer` amb $k = 5$ veïns i ponderació per distància.

La imputació es va aplicar a partir de la variable `apsiii`, prenent com a entrada 40 variables candidates. A més, en aquelles variables que originalment tenien naturalesa entera, els valors imputats es van arrodonir per preservar-ne la interpretació.

Abans de la imputació, el conjunt de dades presentava un total de 20.507 valors absents. Després d'aplicar KNN, aquest nombre es va reduir a 0, de manera que totes les variables incloses en el procés van quedar completades.

8.4 Outliers

Per completar el preprocessat, es va fer una anàlisi específica d'*outliers* sobre la base de dades imputada, amb l'objectiu d'identificar observacions extremes en les principals variables numèriques i revisar si calia aplicar algun tractament addicional. Aquesta revisió es va fer utilitzant dos criteris complementaris, la regla de l'IQR i el *z-score*, i es van generar també representacions gràfiques per facilitar la inspecció visual de les distribucions. Tal com s'indica a l'*script* emprat en aquesta fase, aquesta anàlisi tenia una finalitat principalment exploratòria, ja que el procediment no eliminava automàticament cap observació, sinó que només identificava variables i casos potencialment anòmals per a la seva revisió posterior.

Els resultats obtinguts mostren que la major part dels *outliers* es concentren en variables clarament clíniques i molt vinculades a la gravetat del pacient, com ara l'APSIII, la creatinina, el BUN, la glucosa, el sodi, la temperatura o la diüresi. Precisament, aquestes mateixes variables formen part del nucli clínic del projecte i s'han utilitzat tant en el modelatge com en el *clustering* clínic, perquè aporten informació rellevant sobre severitat global, disfunció orgànica, alteració metabòlica i estat hemodinàmic del pacient.

Per aquest motiu, es va considerar que molts dels valors extrems detectats no s'havien d'interpretar necessàriament com a errors de registre, sinó com a possibles manifestacions reals de situacions clíniques greus dins d'una cohort de pacients amb sèpsia ingressats a l'UCI. Aquesta interpretació és coherent amb la lògica clínica del propi treball, ja que en la fase de *profiling* dels clústers s'observen fenotips greus definits justament per valors molt elevats de creatinina, BUN, APSIII o glucosa, així com per alteracions importants d'altres variables fisiològiques. En particular, el clúster renal-metabòlic greu presenta creatinina màxima alta, BUN màxim molt alt i glucosa màxima elevada, la qual cosa reforça la idea que part dels valors extrems detectats formen part del senyal clínic i no del soroll.

A més, cal remarcar que abans d'aquesta anàlisi ja s'havia fet una revisió de valors inconsistents durant l'etapa d'estandardització. En aquell punt es van detectar i tractar casos clarament incoherents, com ara valors negatius en *offsets* temporals i en la variable `urineoutput`, eliminant o recodificant aquests registres segons correspongués. Això implica que la base final sobre la qual s'ha fet l'anàlisi d'*outliers* ja havia passat un primer filtre de qualitat, i que els extrems conservats després d'aquesta fase eren, en general, plausibles des del punt de vista clínic.

Per tot això, es va decidir no eliminar els *outliers* detectats de manera automàtica. Fer-ho hauria pogut suposar la pèrdua de casos clínicament greus i, per tant, de senyal rellevant per al sistema. En un context com aquest, on l'objectiu és construir un IDSS capaç de captar diferents fenotips i nivells de risc, conservar aquests casos extrems resulta

metodològicament més coherent que no pas suavitzar artificialment la cohort. Així, els *outliers* es van documentar i analitzar, però es van mantenir a la matriu final perquè podien aportar valor tant al model predictiu com a la segmentació clínica dels pacients.

8.5 Variables objectiu

En aquest projecte, la variable objectiu principal de la capa supervisada és `hospital_expire_flag`, que indica si el pacient ha mort o no durant l'estada hospitalària. Es tracta, per tant, d'una variable binària que s'ha utilitzat com a etiqueta del model de predicció de mortalitat. Aquesta elecció és coherent amb l'objectiu general del nostre IDSS, ja que el sistema està orientat a estimar el risc de mortalitat hospitalària en pacients amb sèpsia ingressats a la UCI i a convertir aquesta estimació en una ajuda útil per a la priorització clínica i la monitorització.

La selecció d'aquesta variable objectiu també es justifica des del preprocessat. En concret, la variable `deathoffset` es va eliminar perquè, tot i contenir informació temporal sobre la mort, resultava menys directa per a la formulació del problema i, a més, ja disposàvem de `hospital_expire_flag` com a indicador clar del desenllaç final. D'aquesta manera, el problema es va formular de manera neta com una tasca de classificació binària entre supervivència i mort hospitalària.

Tot i això, l'interès del sistema no rau únicament en la classe final, sinó sobretot en la probabilitat estimada de mortalitat que genera el model. A partir d'aquesta probabilitat, el sistema pot assignar cada pacient a un grup de risc —baix, mitjà o alt— i combinar després aquesta informació amb la capa d'explicabilitat i amb la contextualització per fenotips clínics. Per tant, la variable objectiu original és binària, però la sortida final del model es transforma en una representació més rica i interpretable per al context clínic.

En canvi, en la part de *clustering* clínic no hi ha una variable objectiu en sentit estricte, ja que es tracta d'un procés no supervisat. En aquesta capa, l'objectiu no és predir una etiqueta concreta, sinó identificar fenotips o perfils de pacient a partir de variables clíniques rellevants. Tot i que la mortalitat observada es pot utilitzar posteriorment per descriure i interpretar els clústers, aquesta no guia directament la seva construcció. Així, el *clustering* actua com una capa complementària de contextualització del risc, mentre que la variable objectiu pròpiament dita queda reservada al model supervisat de mortalitat.

8.6 Metadata i resultats

Un cop finalitzada la *pipeline* de preprocessament mitjançant els mòduls `preprocessing_estandarizacio` i `preprocessing_missings.py`, s'ha consolidat una matriu de dades d'alta qualitat. Aquesta secció presenta la definició tècnica de les variables i el resum de l'estat final de la base de dades.

8.6.1 Taula de metadata de la matriu de treball

La transformació de la base de dades s'ha dissenyat per maximitzar la densitat d'informació clínica útil. El procés complet es pot visualitzar en el diagrama de flux global del projecte (vegeu l'inici de l'apartat 10). A continuació es mostra com han canviat les propietats de les variables més representatives:

Taula 2: Canvis aplicats a variables representatives durant el preprocessament

Variable	Estat inicial	Estat final	Canvi aplicat
ethnicity	33 categories disperses	6 grups generals	Agrupació i recodificació numèrica
apsiii	Amb valors nuls	Completa (100%)	Imputació mitjançant KNN ($k = 5$)
urineoutput	Amb valors negatius	Neteja i imputació	Correcció de signes i tractament de buits
deathoffset	Temps fins la mort	Eliminada	Substituïda per l'etiqueta binària <code>hospital_expire_flag</code>

8.6.2 Taula de metadata de la matriu de treball (definitiva)

Totes les variables llistades a continuació formen part del fitxer `BaseDatos_imputada_knn.csv` i presenten un 0% de valors absents.

Taula 3: Taula definitiva de metadata de la matriu de treball

Bloc	Variable	Tipus	Naturalesa / Rol
Identificadors	subject_id, hadm_id, stay_id	Enter	Identificadors únics de pacient i estada
Demografia	gender, admission_age, ethnicity, marital_status	Categòrica / Numèrica	Característiques basals del pacient, recodificades numèricament
Gravetat (scores)	apsiii, apsiii_prob	Numèrica	Índex APS III de severitat fisiològica
Signes vitals	heart_rate_max/min, mbp_max/min, temperature_max/min, resp_rate_max/min	Numèrica	Valors fisiològics extrems durant les primeres 24 hores d'UCI
Laboratori	creatinine_max/min, bun_max/min, glucose_max/min, wbc_max/min, sodium_max/min	Numèrica	Marcadors de funció renal, metabòlica i inflamatòria
Neurològic	gcs_score, gcs_eyes, gcs_verbal, gcs_motor, gcs_unable	Enter	Escala de Glasgow detallada
Desenllaç (target)	hospital_expire_flag	Binària	Variable objectiu: mortalitat hospitalària (0 = viu, 1 = mort)
Context clínic	admission_type, admission_location, urineoutput, sepsis3	Categòrica / Numèrica	Tipus d'ingrés, producció d'orina i diagnòstic de sèpsia

8.6.3 Resum estadístic de la matriu final

Després de l'execució de la *pipeline* de *missings* i estandardització, la matriu resultant presenta les següents dimensions i característiques:

- **Nombre de registres:** 53.493 files (pacients únics amb sèpsia).
- **Nombre de variables:** 55 columnes, incloent els descriptors i la variable objectiu.
- **Densitat de dades:** 100% de dades completes. S'han eliminat 13 variables amb un biaix de nuls superior al 50% i s'ha aplicat KNN ($k = 5$) per a la resta.
- **Inconsistències:** s'ha verificat l'absència de valors negatius en variables de volum (*urineoutput*) i de temps (*los_hospital*).

9 Models

9.1 Data driven

9.1.1 Model 1 - Predicció de mortalitat

El primer model que hem desenvolupat dins del nostre IDSS és el model supervisat de predicció de mortalitat. Aquesta és la peça central de la part *data-driven* del treball, ja que ens permet estimar, per a cada pacient amb sèpsia ingressat a la UCI, una probabilitat individual de mort a partir de les variables clíniques disponibles. L'objectiu d'aquesta capa no és només classificar els pacients en supervivents i no supervivents, sinó sobretot generar una estimació de risc que posteriorment puguem combinar amb la resta del sistema: el *clustering* clínic, la capa d'explicabilitat i, més endavant, la base de coneixement orientada a suportar la presa de decisions.

Des del principi vam considerar que aquesta part havia de complir dues condicions. En primer lloc, el model havia de tenir una capacitat predictiva prou bona com per aportar valor real al sistema. En segon lloc, havia de ser compatible amb una interpretació clínica posterior i amb un ús plausible dins d'un entorn hospitalari. Per aquesta raó, no ens interessava únicament maximitzar una mètrica, sinó construir un model robust, coherent amb el context clínic i integrable dins d'un flux més ampli de suport a la decisió.

Per entrenar aquest model hem utilitzat exclusivament la base de dades imputada *BaseDatos_imputada_knn.csv*. Aquesta és la base final de treball del projecte i conté la informació ja preparada després del procés d'imputació. A nivell metodològic, això és important perquè ens garanteix que tota la modelització es construeix sobre una mateixa matriu consistent, evitant desviacions entre conjunts de dades diferents o dependències respecte a versions intermèdies del preprocessament. A més, el fet de treballar sobre la base imputada ens permet mantenir una mostra gran de pacients i aprofitar millor la informació disponible.

La variable objectiu del model és la mortalitat, formulada com un problema de classificació binària. Això vol dir que per a cada pacient el model ha d'aprendre si el desenllaç final correspon a supervivència o a mort. Tot i això, l'interès principal no rau tant en la classe final com en la probabilitat estimada associada a aquest desenllaç. Aquesta probabilitat és la que després fem servir per estratificar els pacients en nivells de risc i per generar una sortida clínicament més interpretable.

Pel que fa a l'elecció de l'algorisme, hem optat per XGBoost. La decisió no ha estat arbitrària. En dades tabulars com les nostres, on conviuen variables fisiològiques, *scores* de gravetat, dades demogràfiques i valors analítics, XGBoost acostuma a oferir molt bon rendiment perquè és capaç de modelitzar relacions no lineals i interaccions complexes entre variables sense exigir una estructura excessivament rígida. A més, és un model especialment fort quan hi ha heterogeneïtat clínica, com és el cas de la sèpsia, i permet obtenir bones prestacions fins i tot quan l'espai de predictors és ampli i combina senyals de naturalesa diversa. Un altre motiu important per escollir-lo és que, malgrat ser un model potent, continua sent relativament compatible amb tècniques d'explicabilitat, fet que encaixa molt bé amb els objectius del nostre IDSS.

Abans de l'entrenament, hem aplicat un preprocessament específic pensat per fer el model més fiable i més realista des del punt de vista clínic. En aquesta fase hem separat les variables numèriques de les categòriques i hem definit un *pipeline* de transformació adequat per a cada tipus de variable. Com que el fitxer ja estava imputat, no ha calgut repetir la imputació de valors perduts, però sí preparar les variables categòriques perquè poguessin ser utilitzades pel model. Al mateix temps, hem revisat amb cura quines variables podien introduir *data leakage*. En un problema com aquest és especialment important evitar predictors que només es coneixen després del desenllaç o que resumeixen indirectament el resultat final de l'ingrés. Per això hem exclòs variables clarament posteriors a l'evolució clínica completa, com alguns *offsets* temporals de l'alta o la mort i les durades totals d'estada, ja que la seva presència podria inflar artificialment el rendiment del model.

Aquesta decisió metodològica és rellevant perquè volem que el sistema s'aproximi al màxim a un escenari real d'ús. Si l'objectiu final és que l'IDSS ajudi a valorar el risc d'un pacient mentre encara està ingressat, el model només pot utilitzar informació que, de manera plausible, estaria disponible en aquell moment. Per tant, hem prioritzat la consistència clínica per sobre d'una millora aparent de les mètriques basada en informació futura.

Un cop preparades les dades, hem dividit la mostra en conjunt d'entrenament i conjunt de test. Aquesta separació ens permet entrenar el model sobre una part dels pacients i avaluar-lo després sobre casos no vistos, obtenint així una estimació molt més realista del rendiment. El conjunt de test conté 10.699 pacients, una mida prou gran per fer una avaluació robusta i per analitzar posteriorment el comportament del model en diferents subgrups.

El model s'ha entrenat com a classificador binari i, per a cada pacient del conjunt de test, retorna una probabilitat de mortalitat. A partir d'aquesta probabilitat hem calculat diverses mètriques d'avaluació. La més rellevant és la ROC-AUC, que en el nostre cas és de 0,9150. Aquest valor indica que el model té una capacitat molt bona per discriminar entre pacients amb major i menor probabilitat de morir. En altres paraules, si escollim aleatòriament un pacient que mor i un pacient que sobreviu, el model té una probabilitat molt alta d'assignar un risc més alt al pacient que finalment mor.

També hem calculat l'*Average Precision*, que és de 0,6612. Aquesta mètrica és especialment útil en problemes on la classe positiva no és majoritària, com passa aquí, perquè avalua millor la qualitat del model quan ens centrem en la detecció dels casos de risc. El valor obtingut ens indica que el model manté una capacitat de detecció rellevant també des d'aquesta perspectiva. A més, hem avaluat la qualitat probabilística del model mitjançant el *Brier Score* i el *Log Loss*, amb valors de 0,1081 i 0,3402 respectivament. Aquests resultats suggereixen que, en conjunt, les probabilitats predites són raonablement

consistents amb els desenllaços observats.

Taula 4: Mètriques principals del model de predicció de mortalitat

Mètrica	Valor
ROC-AUC	0,9150
Average Precision	0,6612
Brier Score	0,1081
Log Loss	0,3402
Accuracy	0,8434
Precisió classe positiva	0,3761
Recall classe positiva	0,8232

Tot i que l'*accuracy* és elevada, amb un valor de 0,8434, aquesta mètrica no és la que millor descriu el valor clínic del model. En problemes de mortalitat, on la classe positiva és menys freqüent, una *accuracy* alta pot ser enganyosa si el model no detecta bé els pacients que realment moren. Per això hem donat més pes a les mètriques de la classe positiva, especialment a la precisió i al *recall*. En el nostre cas, la precisió de la classe positiva és de 0,3761, mentre que el *recall* arriba a 0,8232. Això vol dir que el model és capaç d'identificar una proporció molt elevada dels pacients que finalment moren, encara que a canvi també classifiqui com a d'alt risc alguns pacients que no acaben tenint aquest desenllaç.

Des d'un punt de vista clínic, aquest comportament ens sembla raonable. En un sistema de suport a la decisió, sovint és preferible tenir un model sensible, que deixi escapar pocs pacients realment greus, encara que després calgui interpretar amb cautela alguns falsos positius. Dit d'una altra manera, ens interessa més captar els casos de risc potencial que no pas construir un sistema massa conservador que només marqui risc quan ja és molt evident.

Per fer la sortida del model més interpretable, no ens hem quedat únicament amb la probabilitat contínua. També hem definit una estratificació en tres grups de risc: baix, mitjà i alt. Aquesta estratificació és molt útil perquè tradueix la sortida probabilística del model a una forma més fàcil d'utilitzar dins d'un IDSS. El grup de risc baix inclou 6.239 pacients, que representen el 58,31% del conjunt de test, i presenta una mortalitat observada de només 0,85%. El grup de risc mitjà inclou 2.580 pacients, és a dir, el 24,11% del total, amb una mortalitat observada del 8,22%. Finalment, el grup de risc alt agrupa 1.880 pacients, el 17,57% del test, però concentra una mortalitat observada molt més elevada, del 43,67%.

Taula 5: Estratificació dels pacients segons el risc predit

Grup de risc	Pacients	% del test	Mortalitat observada
Baix	6239	58,31%	0,85%
Mitjà	2580	24,11%	8,22%
Alt	1880	17,57%	43,67%

Aquesta distribució és especialment rellevant perquè mostra que el model no només obté bones mètriques globals, sinó que també construeix una gradació del risc amb sentit

clínic. El salt entre els tres grups és clar, i la mortalitat observada augmenta de manera molt marcada a mesura que passem del risc baix al risc alt. Això reforça la idea que la probabilitat predita no és un valor abstracte, sinó una estimació que realment capta una diferència de pronòstic entre pacients.

A més, aquest model actua com a eix de la resta del sistema. La probabilitat de mortalitat és la variable que després combinem amb el *clustering* clínic per contextualitzar millor el tipus de pacient, i també és la sortida que expliquem amb la capa d'interpretabilitat. Per tant, no es tracta només d'un classificador aïllat, sinó de la base quantitativa sobre la qual construïm la resta de l'arquitectura de l'IDSS.

També cal destacar que el model ens permet generar sortides útils a nivell individual. Per a cada pacient podem conservar la probabilitat exacta, el grup de risc assignat i, posteriorment, els factors que més han influït en aquesta predicció. Això és important perquè l'objectiu final del sistema no és únicament fer una classificació automàtica, sinó oferir una ajuda interpretable i accionable dins d'un entorn clínic. En aquest sentit, la predicció de mortalitat no és el final del procés, sinó el punt de partida per a una decisió més informada.

Tot i els bons resultats, també hem de remarcar algunes limitacions. En primer lloc, el model ha estat entrenat sobre una base imputada, de manera que part del seu comportament depèn inevitablement de la qualitat del procés d'imputació. En segon lloc, un bon rendiment discriminatiu no garanteix per si sol que el model sigui perfecte en tots els subgrups clínics ni que la calibració sigui òptima per a totes les poblacions. Finalment, com qualsevol model predictiu, aquesta eina no substitueix el criteri mèdic, sinó que l'ha de complementar.

Malgrat aquestes limitacions, considerem que el model de predicció de mortalitat compleix molt bé el seu paper dins del projecte. Ens proporciona una estimació robusta del risc, mostra una capacitat discriminativa elevada i genera una estratificació clínicament coherent. Per això l'entnem com la primera gran capa del nostre IDSS: una capa quantitativa, fiable i útil, sobre la qual després podem afegir interpretació clínica, explicabilitat i coneixement expert.

9.1.2 Model 2 - Clustering clínic per al profiling de pacients

Per complementar el model supervisat de risc, hem implementat una capa de *clustering* orientada a capturar fenotips clínics. La idea de fons és que la probabilitat de mortalitat no sempre és suficient per descriure la situació d'un pacient. Dos pacients poden tenir un risc semblant, però arribar-hi per perfils clínics diferents. Per això hem volgut incorporar una segmentació no supervisada que ens ajudi a parlar de tipus de pacient i no només de nivell de risc.

En una fase inicial vam provar també un enfocament de *clustering_scores*, però finalment hem prioritzat el *clustering_clinical* perquè ens dona grups més útils des del punt de vista clínic. En lloc de limitar-se a ordenar la cohort per severitat agregada, aquest enfocament separa fenotips més interpretables, que després podem creuar amb el model supervisat i amb la capa de coneixement.

Metodologia del clustering.

Hem treballat amb la base imputada i hem seleccionat un conjunt de variables clíniques centrals. En el *preset* clínic hem inclòs especialment:

- edat d'ingrés,

- severitat global (**apsiii**),
- variables neurològiques,
- freqüència cardíaca,
- pressió arterial,
- temperatura,
- freqüència respiratòria,
- creatinina,
- BUN,
- sodi,
- glucosa,
- diüresi.

També hem mantingut algunes variables categòriques de context, com ara sexe, tipus d'ingrés o localització d'ingrés. A nivell de preprocessat, hem fet:

- imputació de categories en les variables categòriques,
- escalat robust de les variables numèriques,
- codificació *one-hot* per a les variables categòriques,
- reducció de dimensionalitat per estabilitzar l'espai de treball.

Un cop preparades les dades, hem comparat diversos algoritmes de *clustering*: **KMeans**, *Gaussian Mixture Model* (GMM) i **Birch**. Hem provat diferents valors de k , entre 3 i 5 clústers, i no ens hem quedat només amb les mètriques geomètriques, sinó també amb la interpretabilitat clínica dels grups i amb la seva utilitat posterior en el sistema.

Resultats generals del clustering clínic.

El resultat final que hem considerat més útil és una solució de cinc clústers. En conjunt, aquests cinc grups ens permeten ordenar la cohort des d'un perfil molt estable fins a fenotips clarament greus. A més, quan els creuem amb el model supervisat de mortalitat, veiem que també es comporten de manera coherent en probabilitat mitjana de risc i en mortalitat observada al conjunt de test.

9.1.3 Profiling dels clústers

A continuació resumim els cinc clústers principals obtinguts amb el *clustering_clinical*.

Cluster 0: fenotip renal-metabòlic greu.

Aquest clúster representa aproximadament el 13,95% de la cohort original. Té una edat mitjana de 65,15 anys i un valor mitjà d'APSIII de 69,38, que ja indica una severitat elevada. El que més el diferencia, però, és el patró analític: la creatinina màxima és molt alta (3,78), el BUN màxim és molt alt (57,10), la glucosa màxima també és elevada i el sodi mínim és baix. A més, la pressió arterial mínima és relativament baixa.

La nostra interpretació és que es tracta d'un fenotip de disfunció renal i alteració metabòlica important. Quan el creuem amb el model de mortalitat, és també el grup amb pitjor comportament: al conjunt de test presenta una probabilitat mitjana predita de 0,541 i una mortalitat observada del 27,7%. Per això l'entendem com el fenotip clínic més greu de la segmentació.

Cluster 4: fenotip neurològic-inflamatori greu.

Aquest grup representa un 15,93% de la cohort. Té un APSIII mitjà de 59,56; per tant, també és un grup sever, però amb una firma diferent de la del clúster 0. Aquí veiem una afectació neurològica més marcada, amb `gcs_score` alt, una temperatura màxima lleugerament més elevada i una pressió arterial màxima alta. En canvi, la càrrega renal és clarament menor que al clúster renal-metabòlic.

La nostra lectura és que aquest grup representa un fenotip greu més lligat a l'afectació sistèmica, neurològica i inflamatòria. Quan el comparem amb el model supervisat, la probabilitat mitjana és de 0,421 i la mortalitat observada és del 16,2%, la qual cosa el situa clarament per sobre dels grups intermedis i estables.

Cluster 2: fenotip intermedi de compromís moderat.

El *cluster 2* agrupa aproximadament un 16,61% de la cohort. Té una edat mitjana relativament alta (68,18 anys) i un APSIII mitjà de 46,16. No presenta la mateixa intensitat de fracàs orgànic que el clúster 0 ni la mateixa càrrega neurològica que el clúster 4, però sí que es manté en una zona clínicament rellevant.

Hi observem un cert compromís metabòlic i fisiològic, encara que sense alteracions extremes. Per això l'hem interpretat com un grup intermedi, especialment útil per a un IDSS perquè pot correspondre a pacients que requereixen vigilància estreta i activació precoç de mesures. En el model supervisat, aquest clúster presenta una probabilitat mitjana de 0,334 i una mortalitat observada del 9,6%.

Cluster 1: fenotip de fragilitat i edat avançada.

Aquest clúster és més petit i representa un 8,39% de la cohort. El tret més destacat és l'edat mitjana, que és la més alta de tots els grups (70,85 anys). També mostra una elevació moderada del BUN i una menor reserva fisiològica general, tot i que sense arribar a la severitat dels clústers més greus.

La interpretació que fem és que aquest grup pot correspondre a pacients més fràgils, en els quals l'edat i la vulnerabilitat basal tenen un paper especialment important. No és el grup més extrem per severitat global, però sí que és clínicament rellevant perquè pot requerir una vigilància més acurada. En el model de mortalitat, presenta una probabilitat mitjana de 0,257 i una mortalitat observada del 7,7%.

Cluster 3: fenotip estable de baixa gravetat.

Finalment, el *cluster 3* és el grup més gran, amb un 45,12% de la cohort. Presenta un APSIII clarament més baix (30,57), una càrrega renal menor, valors de BUN i creatinina baixos, diüresi relativament alta i menys senyals de compromís orgànic global.

Aquest és el grup que interpretem com el fenotip estable o de baixa gravetat. Quan es creua amb el model supervisat, és també el que mostra millor comportament: probabilitat mitjana de 0,108 i mortalitat observada del 3,2%. Per tant, és el clúster més pròxim a una situació de seguiment i monitorització de rutina.

Profiling avançat dels clústers amb aTLP.

Per aprofundir en la interpretació clínica dels clústers, no ens hem limitat a descriure les mitjanes o les variables més representatives de cada grup, sinó que hem incorporat una

capa addicional de *profiling* inspirada en el model aTLP (*annotated Traffic Lights Panel*). Aquesta eina ens ha permès representar de manera estructurada com es comporta cada variable dins de cada clúster en comparació amb la cohort global, i al mateix temps quantificar el grau d'incertesa associat a aquesta caracterització.

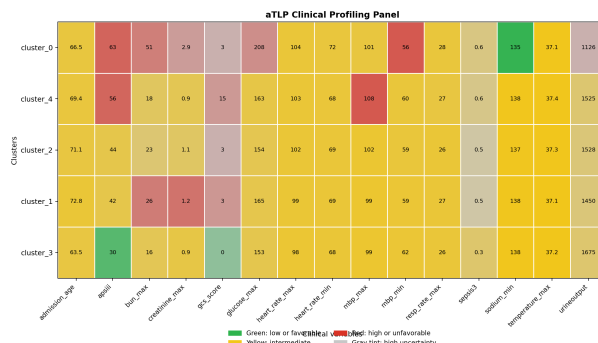


Figura 10: aTLP

La idea de l'aTLP és convertir el perfil de cada clúster en un panell visual tipus semàfor. Per a cada parell clúster-variable, assignem un color segons la posició relativa del valor representatiu del clúster respecte a la distribució global de la cohort. D'aquesta manera:

- verd indica valors baixos o favorables,
- groc indica valors intermedis,
- vermell indica valors alts o desfavorables.

Aquest esquema permet veure d'un cop d'ull quines variables són especialment altes o baixes en cada fenotip clínic. En el nostre cas, ho hem adaptat al context de la sèpsia a la UCI, de manera que el significat clínic del color depèn de la variable. Per exemple, en variables com l'APSIII, la creatinina o el BUN, valors elevats s'interpreten com a pitjors i, per tant, tendeixen cap al vermell. En canvi, en variables com la diüresi o la pressió arterial mínima, un valor més alt pot ser relativament favorable.

Per construir aquest panell, hem treballat sobre els pacients ja assignats als clústers del *clustering_clinical*, recuperant la seva informació original des de la base imputada. Per a cada variable numèrica hem calculat un valor prototípic del clúster, principalment mitjançant la mediana, ja que és una mesura més robusta davant de distribucions asimètriques i valors extrems. Aquest valor s’ha comparat amb els percentils globals de la cohort per decidir la categoria de color corresponent. En el cas de les variables categòriques, hem resumit cada clúster a partir de la categoria dominant i de la seva diferència respecte al mode global.

Una aportació important de l'aTLP és que no es limita a mostrar tendència central, sinó que incorpora també la idea d'incertesa intra-clúster. Això és rellevant perquè dues variables poden tenir el mateix color però no el mateix nivell de fiabilitat interpretativa. Si una variable és molt homogènia dins d'un clúster, la seva interpretació és més robusta; si és molt dispersa, la seva lectura s'ha de fer amb més cautela. Per captar aquesta dimensió, hem calculat una mesura d'incertesa per a cada cel·la del panell:

- en variables numèriques, a partir d'una mesura de dispersió relativa,

- en variables binàries, a partir de la proximitat a una distribució molt barrejada,
- en variables categòriques, a partir de l'entropia normalitzada dins del clúster.

Aquesta incertesa s'ha traduït en una etiqueta qualitativa de confiança alta, mitjana o baixa, i també es reflecteix visualment en el panell. Per tant, l'aTLP no només ens diu si una variable és alta o baixa en un clúster, sinó també si aquesta característica és estable dins del grup o si hi ha una heterogeneïtat interna important.

A nivell pràctic, aquesta capa de *profiling* ens ha aportat tres beneficis principals. En primer lloc, ens ha ajudat a reforçar la interpretació clínica dels clústers. Per exemple, el `cluster_0` mostra clarament un patró renal-metabòlic greu, amb valors elevats de creatinina, BUN i APSIII, mentre que el `cluster_3` es comporta com un fenotip estable de baixa gravetat, amb APSIII baix, menor càrrega renal i millor situació hemodinàmica relativa. En segon lloc, ens ha permès diferenciar millor fenotips que, només amb el resum estàndard, quedaven massa pròxims entre si. Això és especialment útil en els grups intermedis i en els fenotips d'edat avançada. Finalment, ens ha proporcionat una representació molt més explicable i reutilitzable dins del sistema, ja que el panell es pot connectar fàcilment amb la capa de coneixement o amb la generació posterior de descripcions automàtiques per pacient o per clúster.

A més del panell visual, hem complementat aquest *profiling* amb una validació estadística de les variables més discriminants entre clústers. En les variables numèriques hem aplicat el test de Kruskal-Wallis, i en les categòriques hem utilitzat contrastos de khi-quadrat i mesures d'associació com el V de Cramér. Aquesta part reforça la utilitat del *profiling*, perquè no es tracta només d'una representació visual, sinó d'una descripció sostinguda també per evidència estadística.

Els resultats obtinguts mostren que les variables més discriminants són especialment coherents amb la lògica clínica del problema. Destaquen sobretot `gcs_score`, `apsiii`, `bun_max`, `creatinine_max` i `sepsis3`, que són precisament variables molt relacionades amb la gravetat global, el deteriorament neurològic i la disfunció orgànica. Aquest resultat reforça la idea que el *clustering_clinical* no només segmenta els pacients, sinó que ho fa a partir de dimensions clínicament rellevants.

En conjunt, considerem que l'aTLP ha estat una eina molt útil dins del projecte perquè ens ha permès passar d'un *clustering* descriptiu a un *clustering* realment interpretable. No només sabem quins clústers existeixen, sinó també quines variables els defineixen, amb quina direcció i amb quin grau de confiança. Això és especialment valuós en el context d'un IDSS, on la interpretabilitat no és un afegit opcional, sinó una necessitat central per poder transformar un resultat analític en una ajuda real a la presa de decisions.

9.1.4 Model 3 - Explicabilitat i integració amb la capa de coneixement

El sistema de suport a la decisió clínica (IDSS) que estem implementant és un flux de treball de tres capes que integra diversos components per proporcionar una estimació fiable i explicable del risc de mortalitat dels pacients amb sèpsia a l'UCI. Aquest procés inclou la predicció de mortalitat, l'assignació fenotípica mitjançant *clustering* i la generació d'un *prompt* clínic explicatiu per a un model de llenguatge (LLM), tot integrat amb una capa de coneixement basada en informació clínica i guies de tractament. Al sistema se li insereixen les dades d'un pacient nou, i a partir d'aquí es fa la predicció, l'assignació de fenotip i es genera el *prompt* per a un LLM.

9.1.4.1 Predicció del risc de mortalitat amb XGBoost El primer component del *pipeline* és la predicció de la mortalitat utilitzant un model supervisat de XGBoost. A partir de les dades clíniques i fisiològiques dels pacients (com la creatinina, la temperatura, l'escala APSSII, etc.), el model calcula una probabilitat individual de mortalitat per cada pacient. Aquesta probabilitat s'assigna a un grup de risc (baix, mitjà, alt) en funció dels llindars de risc establerts en les metadades del model.

Una vegada obtinguda la predicció, el sistema explica quines variables han tingut més influència en la classificació del pacient, identificant tant les variables que han augmentat com les que han disminuït el risc de mortalitat. Això és essencial per proporcionar als professionals de la salut una visió clara de per què el sistema ha fet aquesta predicció.

9.1.4.2 Assignació fenotípica mitjançant clustering El segon component del *pipeline* és el *clustering* clínic, que assigna el pacient a un fenotip clínic basat en les seves dades històriques i similituds amb altres pacients. Aquest procés fa servir una combinació de tècniques com SVD (descomposició en valors singulars), escalat i *embeddings* de pacients històrics per calcular les distàncies entre el pacient actual i altres pacients, utilitzant una mètrica de similitud. Un cop assignat el pacient al clúster, es genera un perfil de clúster que ofereix una interpretació clínic del tipus de pacient que s'està tractant (per exemple, “renal-metabòlic greu” o “neurològic-inflamatori greu”).

Aquesta assignació ajuda a contextualitzar el risc de mortalitat i proporciona informació més detallada sobre les possibles condicions subjacents que poden influir en el pronòstic del pacient.

9.1.4.3 Generació del prompt clínic final El tercer component del sistema és la construcció del *prompt* clínic per a un model de llenguatge (LLM). A partir de les prediccions del model de XGBoost i l'assignació fenotípica, es genera un JSON estructurat que inclou tota la informació rellevant del pacient (identificadors, predicció de mortalitat, clúster assignat, perfil de clúster, etc.). Aquest JSON es passa al model de llenguatge, que interpreta aquesta informació i genera explicacions detallades i accions recomanades per al personal clínic.

El *prompt* clínic es genera de la següent manera:

- **Base de coneixement:** es carrega la base de coneixement clínic proporcionada, que inclou guies clíniques, protocols de tractament i recomanacions de monitorització adaptades al context de la sèpsia. Aquesta base de coneixement s'utilitza com a referència per interpretar el cas del pacient i ajudar a prendre decisions informades.
- **Dades del pacient:** el *prompt* inclou el context estructurat de l'entrada del pacient (informació clínic, resultats del model de mortalitat i assignació de clúster) en format JSON. Això proporciona al model de llenguatge tota la informació necessària per generar respostes coherents i útils per al metge.
- **Format del prompt:** un cop es combina la base de coneixement amb el context del pacient, el sistema genera un text explicatiu en llenguatge natural, seguint un format predeterminat. Això inclou:
 - resum del risc de mortalitat (incloent la probabilitat i el grup de risc),
 - interpretació clínic: explica els factors que han influït en el risc i quins òrgans o sistemes poden estar més afectats,

- context del clúster: assigna al pacient un fenotip clínic i ofereix una interpretació d'aquest basant-se en la cohort històrica,
- accions recomanades: proposa les actuacions prioritàries en funció del coneixement expert i les guies clíniques (per exemple, antibioteràpia precoç, fluidoteràpia, etc.),
- informació faltant: si falten dades importants, es suggereix què cal demanar o reavaluar.

La idea és passar aquest *prompt* a un LLM com Gemini a través d'una API. D'aquesta forma, el LLM té el context suficient per fer una explicació clara i entenedora sobre els resultats de la predicció, la classificació en el *clustering* i recomanacions de tractaments per al pacient en funció dels resultats obtinguts. El *prompt*, en si mateix, són les instruccions de què ha d'explicar i quines recomanacions proposar segons les dades del pacient.

9.1.4.4 Integració amb la capa de coneixement El coneixement expert es combina amb els resultats generats pels models predictius per crear una resposta coherent i útil per als professionals sanitaris. Aquesta capa de coneixement inclou informació provinent de guies clíniques i protocols de tractament, i es relaciona amb el clúster assignat al pacient. Això permet contextualitzar el cas en un fenotip específic i proporcionar recomanacions d'actuació personalitzades que van des de la monitorització intensiva fins a l'activació de protocols d'urgència, tot basat en les dades clíniques reals i la millor evidència disponible.

9.2 Knowledge driven

9.2.1 Formalisme

El coneixement es representa principalment mitjançant una base de coneixement que s'alimenta de fonts clíniques reconegudes, com guies de pràctica clínica i recomanacions de consens, com la Guia CUN 2018 i el Documento de Consenso sobre Sepsis. Aquesta base de coneixement conté informació detallada sobre els criteris diagnòstics, els protocols de tractament i les recomanacions basades en el coneixement expert, els quals es tradueixen en regles d'inferència que guien la presa de decisions en el sistema.

9.2.2 Estructura principal

La base de coneixement es compon de diversos components clau:

- **Criteris de diagnòstic:** inclou els criteris com el SOFA (*Sequential Organ Failure Assessment*) i qSOFA per identificar i classificar la sèpsia en les seves diverses formes (sèpsia, xoc sèptic, etc.).
- **Protocol de tractament:** regles per a la fluidoteràpia, vasopressors, antibioteràpia empírica i dirigida, així com el control de focus d'infecció.
- **Recomanacions basades en fenotips:** assignació de pacients a clústers clínics basats en les seves condicions subjacents i la seva resposta als tractaments, com “renal-metabòlic greu” o “neurològic-inflamatori greu”. Aquesta part prové del *clustering* que hem obtingut en el model explicat anteriorment.
- **Marcadors diagnòstics:** inclou biomarcadors com la procalcitonina (PCT) i la proteïna C reactiva (PCR), que ajuden a diagnosticar la sèpsia i a estratificar el risc.

9.2.3 Font de continguts (experts, literatura, models basats en dades, etc.)

Els continguts d'aquesta base de coneixement provenen de múltiples fonts:

- **Experts clínics:** els protocols i les directrius han estat establerts per professionals de la salut i societats científiques.
- **Literatura científica:** la informació recollida inclou estudis clínics i consensos globals com la *Surviving Sepsis Campaign* i altres guies clíniques.
- **Models basats en dades:** els fenotips obtinguts dels models de *clustering* i *profiling*, amb informació afegida provinent de la literatura segons les característiques de cada clúster.

9.2.4 Paper en el sistema

La base de coneixement serveix com a font d'informació per a la generació de recomanacions clíniques personalitzades. Quan el sistema genera un diagnòstic de sèpsia i assigna un pacient a un clúster fenotípic, utilitza la base de coneixement per identificar el tractament adequat i les accions prioritàries. Aquesta integració permet al sistema oferir recomanacions que es basen en evidències actualitzades i millorar la qualitat de l'atenció. Tota aquesta informació és amb la que es genera el *prompt* del model d'explicabilitat.

9.2.5 Forma de l'output, resultats i validació del model

Els resultats generats pel sistema del model, com hem explicat abans, es presenten com a recomanacions en format textual per a ser utilitzades pels metges, incloent les següents dades:

- **Predicció del risc:** es genera una probabilitat de mortalitat per cada pacient, classificada en risc baix, mitjà o alt.
- **Recomanacions d'acció:** basades en els clústers assignats i el coneixement integrat, el sistema suggereix actuacions com antibioteràpia, fluidoteràpia i la necessitat de control de focus.
- **Validació:** el sistema és validat mitjançant comparació amb les guies clíniques existents i mitjançant el seu ús pràctic en contextos hospitalaris per part dels metges.

9.2.6 Descripció de la integració amb l'arquitectura general

La base de coneixement s'integra en el flux de treball general del sistema a través del `new_patient_pipeline.py`, que es connecta amb el model de predicció de mortalitat (XGBoost) i el sistema de *clustering*. Després de calcular la predicció de mortalitat i assignar un clúster fenotípic, es genera un *prompt* clínic estructurat que inclou informació de la base de coneixement per proporcionar recomanacions clíniques detallades. Aquest *prompt* es passa a un model de llenguatge (LLM), que genera explicacions i recomanacions per a l'equip clínic.

La base de coneixement és essencial per garantir que les recomanacions del sistema siguin coherents amb les pràctiques clíniques establertes i proporcionar suport per a la presa de decisions en temps real.

13 Conclusions

En aquest treball hem desenvolupat la proposta d'un *Intelligent Decision Support System* orientat a pacients amb sèpsia ingressats a la UCI, amb l'objectiu de donar suport a decisions de triatge, priorització i monitorització clínica. La idea central del sistema ha estat anar més enllà d'una predicció aïllada i construir una arquitectura que integri tres dimensions complementàries: l'estimació quantitativa del risc de mortalitat, la contextualització del pacient mitjançant fenotips clínics i una capa d'explicabilitat i coneixement que faci la sortida més interpretable per al personal sanitari.

Un dels principals resultats del treball ha estat la consolidació d'una base de dades final robusta i preparada per al modelatge, amb 53.493 registres, 55 variables i un 100% de dades completes després del procés d'estandardització, eliminació selectiva de variables i imputació mitjançant KNN. Sobre aquesta base s'ha construït el model supervisat de predicció de mortalitat amb XGBoost, que ha mostrat una capacitat discriminativa elevada, amb una ROC-AUC de 0,9150, i una estratificació en grups de risc que presenta una clara coherència clínica, ja que la mortalitat observada augmenta de manera molt marcada del grup baix al grup alt. Aquests resultats indiquen que el model és capaç de captar diferències pronòstiques reals entre pacients i que pot constituir una base sòlida per a un sistema de suport a la decisió.

A més de la capa predictiva, el *clustering* clínic ha aportat un valor afegit important al sistema, ja que ha permès identificar fenotips diferenciats de pacient i entendre millor que un mateix nivell de risc pot correspondre a perfils clínics diferents. La solució final de cinc clústers, reforçada amb el *profiling* mitjançant aTLP, ha contribuït a fer aquesta segmentació més interpretable i més útil des del punt de vista clínic. Això ens sembla especialment rellevant en el context d'un IDSS, perquè la utilitat real del sistema no depèn només del rendiment numèric, sinó també de la seva capacitat per explicar què està passant i per quins motius un pacient s'associa a un determinat nivell de gravetat o a un determinat fenotip.

Finalment, considerem que el sistema proposat constitueix una base prometedora per a un IDSS clínic més complet, ja que combina models *data-driven* amb una capa *knowledge-driven* orientada a generar recomanacions en llenguatge natural i mantenir una interacció *human-in-the-loop* amb el professional sanitari. Tot i això, el treball també presenta limitacions que cal tenir presents, especialment la dependència respecte al procés d'imputació, la necessitat de validar el comportament del sistema en diferents subgrups clínics i la conveniència de realitzar validacions externes i proves en entorns d'ús més reals. Com a continuació natural del projecte, seria interessant aprofundir en la calibració del model, completar la integració amb el LLM i la base de coneixement clínica i validar l'IDSS com a eina de suport operatiu dins del flux assistencial de l'UCI.